

MATHIEU RIVIÈRE

Étudiant en M1 « Humanités numériques et computationnelles »

École nationale des chartes · Université PSL

mathieu.riviere@chartes.psl.eu · icimathieu.github.io · github.com/icimathieu · huggingface.co/icimathieu

PROFIL

Étudiant en humanités numériques, je travaille à l'application de méthodes computationnelles à l'histoire contemporaine : exploitation de sources numérisées (voire numériques) et traitement automatique de la langue. Mon mémoire d'histoire des sciences porte sur la pasteurisation de la France métropolitaine (1870-1914) et croise pastoriens, revues scientifiques, presse et parlementaires sous la III^e République ; il mobilise scraping, OCR, structuration de corpus, annotation, RAG et classification.

Perspectives : agrégation d'histoire puis doctorat à forte composante numérique et computationnelle.

FORMATION

- 2025 – **Master « Humanités numériques et computationnelles »**
École nationale des chartes, École normale supérieure & Université PSL
Séminaires de recherche en histoire et philosophie (EHESS, ENS) ; travaux dirigés d'humanités numériques (ENC) ; cours magistraux de géographie (Sorbonne).
Membre de la Junior-Entreprise CartaData, sollicité pour des prestations variées.
- 2022 – 2025 **Licence d'histoire** — mention Très Bien
Université Paris 1 Panthéon-Sorbonne
Compléments en histoire et informatique ; séminaires d'histoire et de philosophie ; auditeur libre en licence de science politique ; cours du soir au Louvre.
- 2021 – 2022 **CPGE PCSI** — Lycée Saint-Louis (Paris 6^e)
Classé 23^e/46.

EXPÉRIENCE DE RECHERCHE

- Mai – déc. 2026 **Stage de recherche — reconnaissance d'entités nommées (NER)**
Projet ANR DECIDON — EPITA · ENC · EHESS
Étude computationnelle de la vie parlementaire sous la III^e République (1870-1940) : circulation des problèmes publics entre presse et Parlement et mécanismes de mise à l'agenda. Conception du guide et du schéma d'annotation et coordination des annotations ; sélection, entraînement et inférence de modèles de NER ; à venir : détection d'évènements. Stage équivalent à 5 mois à temps plein.
- Janv. – avr. 2025 **Stage — édition numérique et textométrie**
Groupe CACTUS, ENS de Lyon
Participation à l'édition numérique de textes médiévaux de la [Base de Français Médiéval](#) : recherche et intégration de métadonnées ; correspondances manuscrits/textes ; relecture d'éditions ; annotation de zones (bounding boxes) sur enluminures.

PROJETS EN HUMANITÉS NUMÉRIQUES (SÉLECTION)

- 2026 **Cartes postales du Vaucluse** — pipeline VLM & cartographie (Hackathon ENC et Junior-Entreprise CartaData)
OCR de cartes postales par VLMs, extraction et nettoyage de métadonnées, requêtage de bases de données via API comme garde-fou, géoréférencement, structuration JSON/CSV et production d'une carte interactive (HTML). Nous généralisons désormais cette pipeline pour offrir nos services à d'autres fonds d'archives.
Dépôt : github.com/icimathieu/vaucluse
Portfolio : huggingface.co/spaces/icimathieu/cartes_portfolio

- 2025 – **Mémoire** — construction d'un corpus de la pasteurisation (1870-1914)
Mémoire d'histoire des sciences, sous la direction d'Anne Rasmussen (EHESS) et de Marie Puren (EPITA, ENC).
Scraping Gallica et extraction de métadonnées; OCR de revues scientifiques (fin XIX^e–début XX^e) avec benchmark de plusieurs modèles; structuration de corpus et bases de données.
Dépôts : [scraping_pdf](#) · [transcription](#) · Mini-mémoire (PDF) : [latex_memoire](#)
- 2026 **FromLego2Hero** — reconstitution de mosaïques
Projet de groupe (cours de Python). Reconstitution de mosaïques fragmentées en tesselles (ou groupes de tesselles) par VLM et/ou réseaux de neurones sur graphes (GNN). Génération massive de données synthétiques (mosaïques Lego) pour permettre un transfert de connaissance entre les deux types de mosaïques; techniques de dégradation de données pour généraliser l'apprentissage. Travail soumis à une conférence d'humanités numériques.

COMPÉTENCES TECHNIQUES

Programmation & data — Python (numpy, pandas, networkx, scikit-learn, PyTorch, API OpenAI, folium); graphes de connaissances et GNN, génération de données synthétiques (augmentation, dégradation); HTML, JavaScript, RSS.

Scraping — BeautifulSoup (parsing HTML), Selenium (contournement d'anti-bots), Scrapy (*crawling*) — presse et archives (Gallica, *Le Monde diplomatique*, Archives du Vaucluse); IIIF et APIs patrimoniales (Gallica, BnF).

OCR, vision & annotation — PaddleOCR, Tesseract, pero-ocr, YOLO (local); Qwen-VL, Gemini (API); Label Studio; conception de schémas et guides d'annotation.

TAL & textométrie — TXM, Iramuteq; n-grammes, mots-fonctions, distances; classification, NER, RAG, stylo-métrie, détection d'émotions.

Structuration & édition — XML-TEI, XPath, SQL, LaTeX; workflows d'édition numérique; notions de bases de données.

Outils — Git/GitHub, Hugging Face, LLMs (via API ou en local); pilotage de machines distantes et de serveurs (SSH).

LANGUES

Français langue maternelle · **Anglais** C1 (TOEIC 860, 2020) · **Allemand** B1–B2.

DIFFUSION & VULGARISATION

2023 – 2026 **Histosef** — vidéaste
Production de contenus audiovisuels de vulgarisation historique sur YouTube, à partir de lectures scientifiques et d'essais.

2024 – 2025 **L'Ouvreuse** (webzine, Sorbonne) — rédacteur

AUTRES EXPÉRIENCES

2023, 2024 **Agent d'accueil et de surveillance**
Musée d'art et d'histoire Baron Gérard, Bayeux

2022 – 2023 **Cours particuliers**
Mathématiques et disciplines scientifiques (niveau lycée).